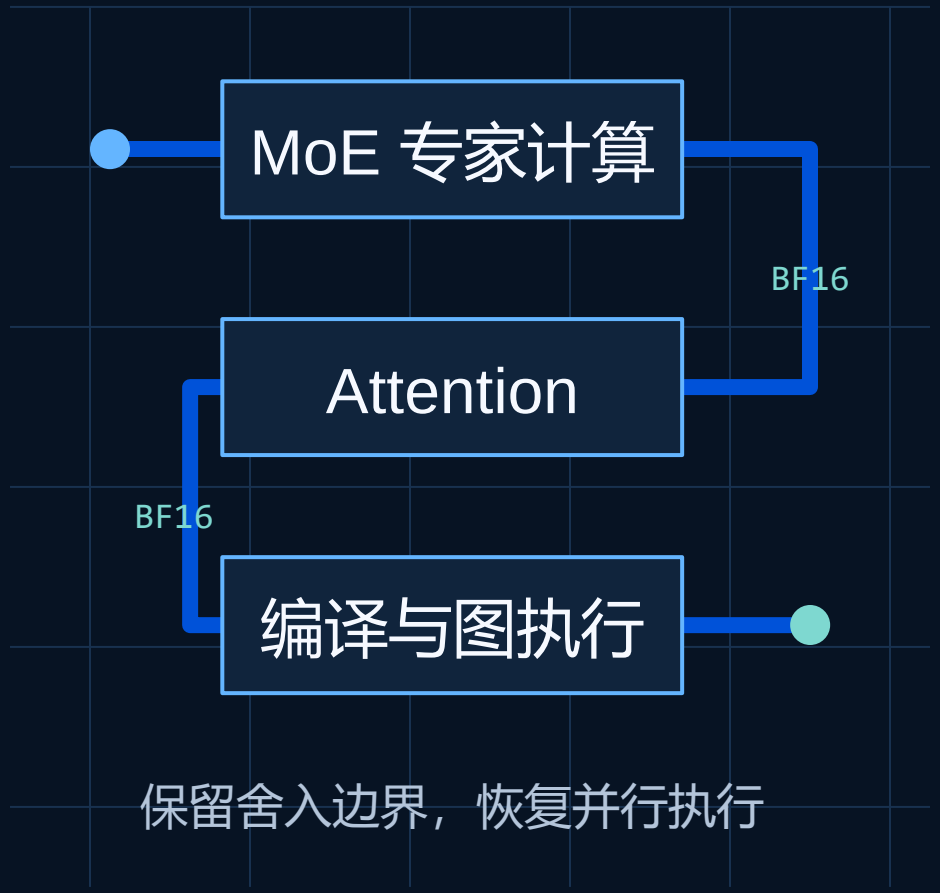
正确性先行
三点推理优化

Mellum 2.1 · ATOM · 单卡 MI308X

完整精度验收 / 独立开关 / 可复现实测



蒋天颢

2026 年 11 月 · 10 分钟讲解 + 10 分钟问答

三种场景，三种评价指标

A 看每卡吞吐，C 看长请求造成的尾时延。

场景	请求数	负载设置	核心指标
A · 吞吐	512	并发 32 输入 512–4K	输出 token/s/GPU ↑
B · 单流	50	并发 1 输入 1024	TPOT p50 ↓
C · 开放环	200	0.30 请求/秒 输入 4–16K，泊松到达	TPOT p99 / TTFT p99 ↓

单卡 · 输出 256 token · 流式 · greedy · 忽略 EOS

性能基线只取 baseline.json；B 未提供基线。公开测试与隐藏验收分开。

来源：题目第 6 节；A 原始数据中 5 条略超 4K，保留原始 512 条并单列过滤补充结果。

先修复数值边界，再恢复并行

固定输入接近，不等于自回归输出一致。

C200 · 每条前 64 token · 全部一致

12800/12800

严格 16K 输入：64 个生成 token 完全一致

HumanEval pass@1

148/164

与 HF 相差 0 个百分点

164 条完整输出也逐题一致

逐算子检查 → 整模型自由生成 → 完整门槛验收

BF16 舍入 / shape / K 顺序

不喂入参考答案的前缀

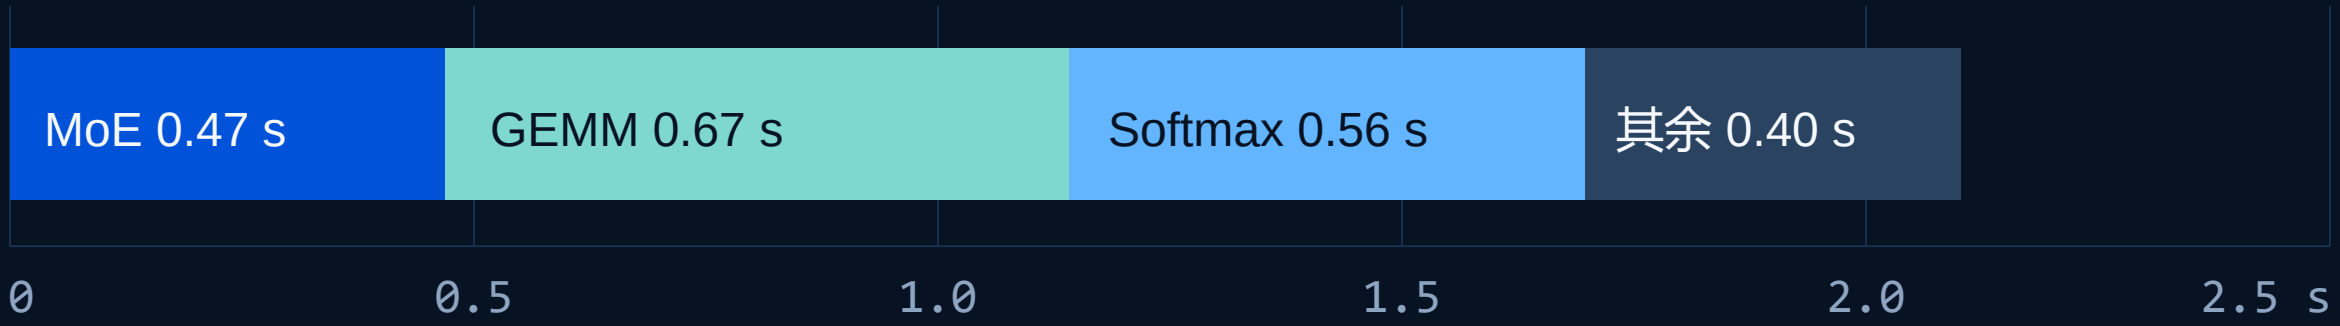
C200 / 16K / HumanEval

证据：fast_full_correctness_20261105T165619Z；单卡 BF16，MTP 关闭；公开集通过不等于隐藏集验收。

真实时间线定位剩余瓶颈

16k 长请求：矩阵乘与 softmax 仍占大头。

当前版本：16384 输入、8 个输出；GPU kernel 累计时间，非请求延迟。

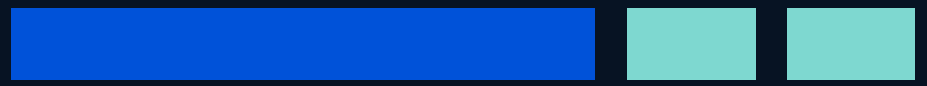


5,699 个 kernel 事件

GEMM 32.0%；softmax 26.5%

GEMM 含线性与注意力，不能全算作 Attention。

长预填充会延后解码



预填充 / 解码排队示意；实测收益看开关消融。

torch profiler：delivery_profile_20261105T183352Z；按 kernel 名称归类；正式性能测试关闭 profiler。

点一：让 MoE 专家计算回到原生核

减少专家权重搬运与碎片化计算。

64 专家 × top-8 · hidden 2304 · 中间维 896

路由与排序

融合权重归一化

两阶段复用计划

→

专家第一阶段

Gate / Up + SiLU

保持中间 BF16 舍入

→

专家第二阶段

Down × 路由权重

按形状选择 K 顺序

→

独立 slot 输出

避免专家输出冲突

固定归并后返回

按计算形状分派，不按提示内容分派。

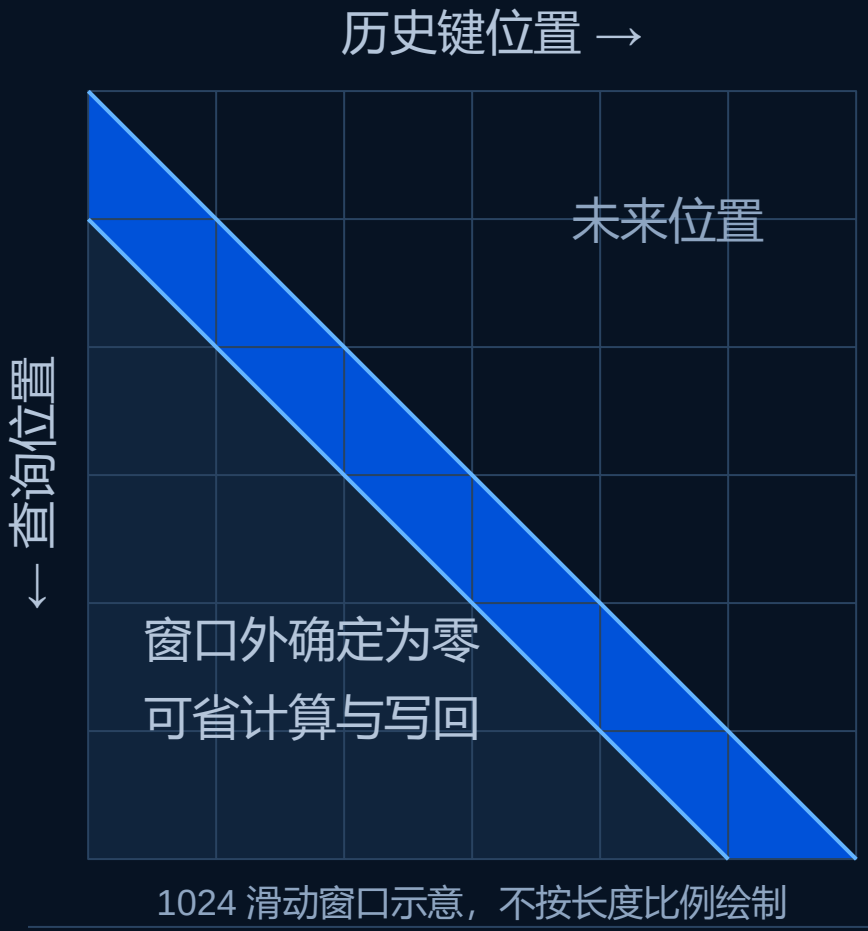
从原生 CK/AITER 核修改累加与舍入边界；用逐值检查和整模型门槛约束。

`--moe-opt 0/1`　　预估依据：MoE 耗时份额；实测贡献：第 8 页累计消融。

实现：mellum_native_decode_moe / prefill_stage1 / prefill_down；修改后的 AITER、CK 源码及历史均随仓库交付。

点二：只计算注意力需要的区域

滑动窗口约束与数值等价约束同时满足。



1024 滑动窗口示意，不按长度比例绘制

21 层滑窗，7 层全注意力

窗口 QK → 保序 softmax → 窗口 PV

保留 BF16 舍入与归约顺序

形状族选择参数；不满足布局条件则回退。

16K 算子微基准（ms）

PV 12.19 → 2.65

softmax 30.28 → 5.84

`--attention-opt 0/1`

证据：pv_operator_validation / window_sparse_validation；同卡微基准，非整模型加速比。

点三：编译计算片段，复用解码图

动态元数据留在图外，稳定计算减少 CPU 重复提交。

01
准备元数据
序列长度与 KV 索引

→

02
编译稳定片段
保留必要的数值边界

→

03
捕获并复用
固定缓冲与批次覆盖

→

04
回放与输出
完整模型校验 token

计时边界明确

冷启动与首次捕获单列；正式吞吐不启用 profiler。

同进程完成精度验证后，固定负载重复三轮取中位数。

解码图批次

1 / 2 / 4 / 8 / 16 / 32

`--compile-graph-opt 1`

默认：片段编译 + ATOM 解码图；片段图单独关闭。开关关闭时使用 eager 对照。

逐项开启，验证各点实际贡献

相同输入与协议；不相乘独立实验的加速比。

配置	卡数	A token/s/GPU ↑	B TPOT p50 ↓	C TPOT p99 / TTFT p99 ↓
Step 0	1	64.53	47.47	289.82 / 21054.52
+ 点 1	1	104.10	45.82	243.99 / 15857.43
+ 点 1 + 2	1	444.91	42.59	85.50 / 2109.18
+ 点 1 + 2 + 3	1	727.97	9.21	38.39 / 2069.40

受控小测：A64 / B8 / C12 × 1 轮；时延单位 ms；每组先校验 832 个 token。
C 的小样本 p99 只用于筛选；最终候选另做 A512 / B50 / C200 三轮全量。

证据：cumulative_ablation_20261105T180217Z；四组均通过 832 / 832 token 检查。

全量结果逐项对照题目基线

A 吞吐已超过基线，C 两项尾时延仍未达标。

当前三轮中位数　题目基线

A · 吞吐 ↑

token/s/GPU



697.74

较基线 +9.31%

C · TPOT p99 ↓

基线 41.27 ms



68.33 ms

基线的 1.66 倍

C · TTFT p99 ↓

基线 993.55 ms



4387 ms

基线的 4.42 倍

B 单流 TPOT p50：9.205 ms

B 未提供官方基线；不推算加速比。

公开集 A512 / B50 / C200，各三轮；源码快照不变；运行 20261105T170206Z；非隐藏集验收。

选择三点，也要解释放弃什么

收益、精度、复现成本，共同决定最终取舍。

纳入三个优化点

MoE 专家计算

工具时间线显示显著耗时；路由、专家核、
有序归并构成自包含的计算优化。

Attention 计算

21 层滑窗存在可省计算；逐核验证
QK、softmax、PV 的数值边界。

编译与图执行

面向重复解码的提交开销，提供 eager 对照。

未纳入默认交付

MTP：保留研究记录，默认关闭

短提示收益不能代替完整负载与 on/off 验收。

双卡：必须证明每卡受益

总吞吐翻倍不足以证明归一化收益。

量化：需要重新通过精度门槛

缺少完整验收，不计入当前成果。

缓存与调度：留作后续方向

三点预算已满；形状改变后需重新对齐。

一条命令，启动经过实际生成检查的服务

默认单卡 BF16，三个点开启，MTP 关闭。

```
bash scripts/start_server.sh
```

代码
保留完整 Git 历史
`README-CSIG.md`

→

服务
真实生成 8 个 token
`manifest.json`

→

评测
性能与正确性分开
`results/`

→

证据
命令、哈希与日志
SQLite / trace

`--moe-opt 0/1` `--attention-opt 0/1` `--compile-graph-opt 0/1`

在题目冻结容器内运行；依赖与源码随仓库交付，不更换环境或下载权重。

能复现的收益，才计入最终结论。

AI 辅助	提出建议 → 寻找反例 → 实验确认与人工决策
工作日志	记录卡点 → 解释转向 → 保留完整提交历史

进入 10 分钟问答

备页：AI 使用 / D1–D7 / 精度 / 复现

随交付附：四页报告、AI 使用说明、WORKLOG.md、原始证据与逐页讲稿。

备答｜AI 帮助了什么，也错在哪里

Codex / 词元工坊：读代码、写探针、改算子、分析日志。

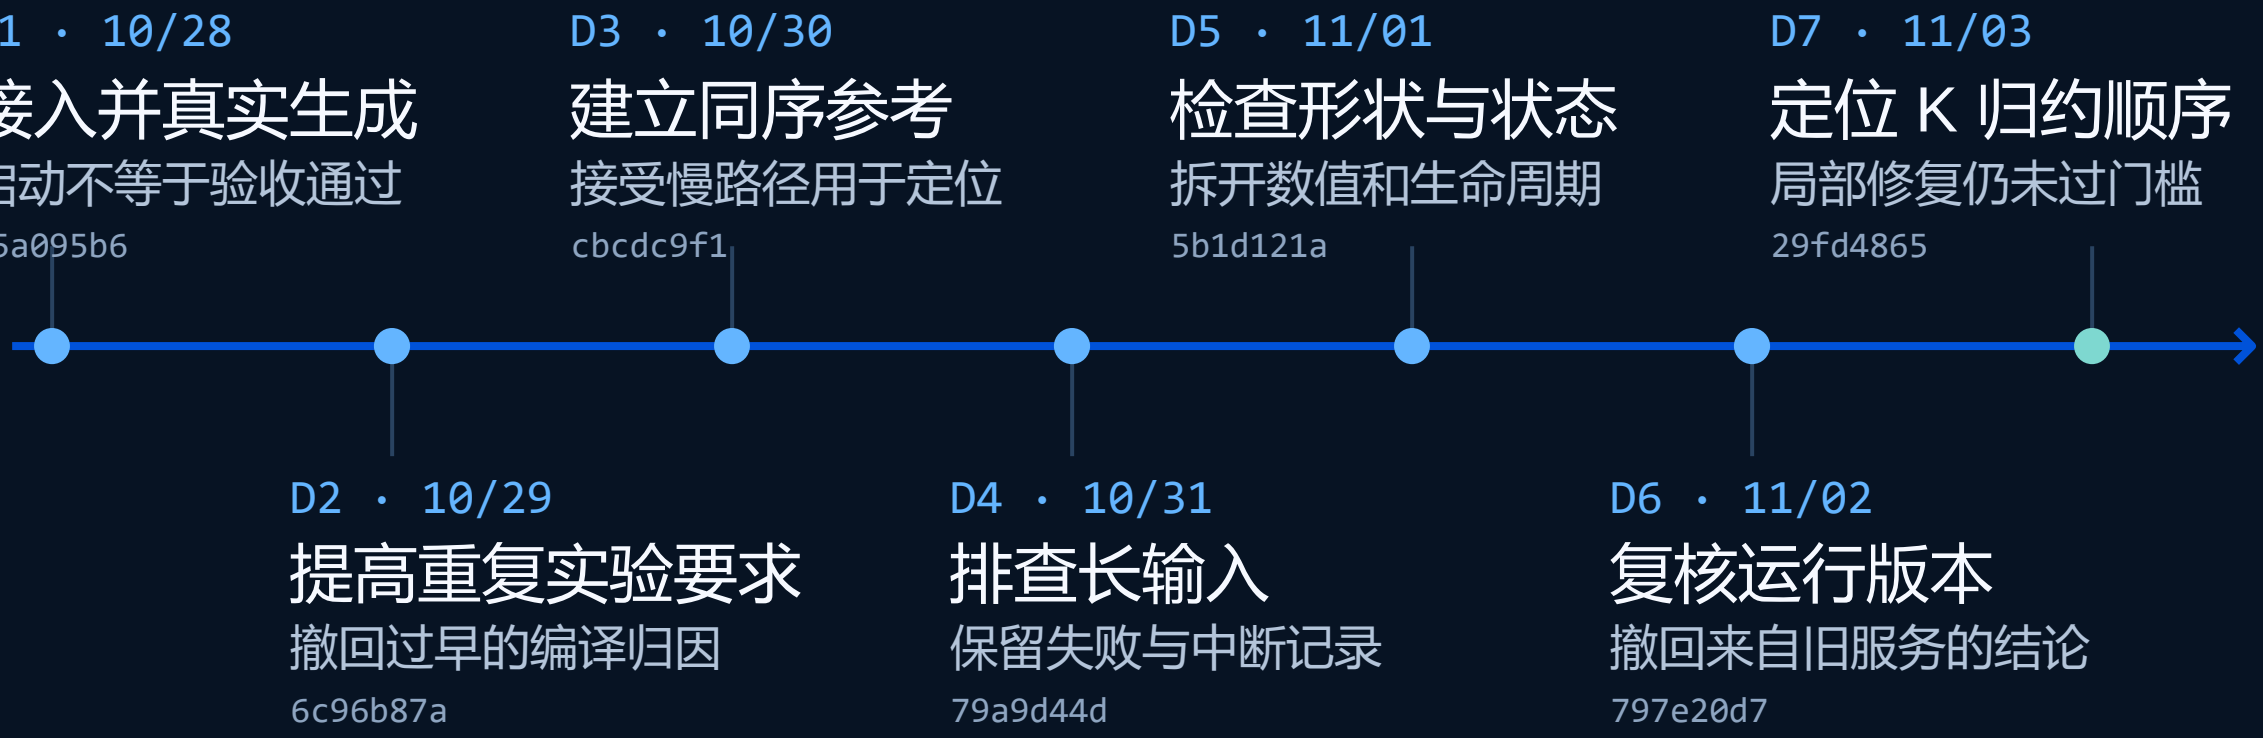
容易误判的建议	发现问题的证据	最终决策
局部对齐被说成已解决	同阶段结果表中，实际快路径仍没有通过完整生成门槛。	区分定位、修改与验收；每项结论标明适用范围。
喂入参考前缀来比较	它可以诊断中间张量，题目验收却要求自由生成。	保留为诊断工具；回到原始验收协议。
MTP 注意力前提错误	对照模型结构与已有实现，发现设计假设不成立。	先核实结构再写代码；用 on/off 实验验证修正。

我需要掌握目标、baseline 和当前运行版本。

来源：AI-USE.md；完整说明保留工具用途、错误建议与个人决策反思。

备答｜D1–D7：卡点、转向与决策

按真实日历记录；补充工作单列，不倒填。



补充：11/4 完整精度 → 11/5 原生优化 → 11/6 全量复测与交付整理

来源：WORKLOG.md 与提交索引；教训：应更早锁定 Step 0 验证协议。

备答｜精度门槛与证据边界

每项通过结论，都绑定配置、输入与生成协议。

检查	题目要求	当前结果	范围说明
C200	前 64 token 一致率 ≥90%	12800 / 12800	200 条均完全一致
严格 16k	长上下文单独统计	64 / 64	输入恰为 16384 token
HumanEval	BF16 差距 ≤2 个百分点	148/164；差距 0	同协议 HF 为 148/164
MTP	开启时 on/off 完全一致	默认关闭	不声明开启配置通过
双卡	声明双卡时重新验收	声明单卡	不外推到双卡配置

附近文件的 3/164 已被 baseline 标记为无效协议；没有把它当作 HumanEval 对照。

证据：fast_full_correctness_20261105T165619Z；同协议 HF 对照，生成参数见报告。

备答｜复现时，必须同时固定四件事

环境、代码开关、输入负载与统计方式。

冻结环境

MI308X × 1

固定库与二进制哈希

`environment.json`

→

运行配置

代码、开关与设备

默认 MTP 关闭

`manifest.json`

→

输入负载

A512 / B50 / C200

输出固定为 256

`protocol.json`

→

统计方式

三轮指标取中位数

计时关闭 profiler

SQLite / JSON

```
bash scripts/benchmark.sh --repeat 3
```

```
/opt/venv/bin/python3 scripts/validate_public.py
```

A 通过 line_by_line 原样传递 prompt；5 条略超 4k 的原始记录不改写。
冷启动与首次捕获单列；公开集三轮测试不替代裁判的隐藏集验收。

完整命令、冻结版本、依赖来源、服务停止方式与原始证据索引均随仓库交付。